ĐỀ XUẤT THIẾT KẾ KIẾN TRÚC HỆ THỐNG DỰ BÁO THỜI GIAN ĐẾN CỦA XE BUÝT (ETA)

Tiếp cận dựa trên Dữ liệu Lớn và Kiến trúc Lambda

Nhóm Sinh Viên Thực Hiện

Đại học Bách khoa Hà Nội – Trường Công nghệ Thông tin và Truyền thông

Tháng 10 Năm 2026

1. Đặt Vấn Đề và Bối Cảnh Kỹ Thuật

Thách thức Giao thông Đô thị

- Hành khách cần chỉ số **ETA chính xác** để chủ động hành trình.
- Giao thông Hà Nội biến động mạnh theo khung giờ cao điểm và sự cố đột xuất.

Hạn chế của API Mở (BusMap)

- Bản chất **Stateless Snapshots**: chỉ trả về tọa độ tức thời tại lúc gọi.
- **Không lưu lịch sử**: không thể phân tích phân phối vận tốc theo giờ.
- **Thiếu ngữ cảnh**: không có dữ liệu sự cố tắc nghẽn trên hành lang.

Mục tiêu Giải pháp Dữ liệu Lớn

Hiện trạng: API Stateless

Ảnh chụp tức thời $\rightarrow$ Mất dấu hành trình

$\Longrightarrow$ Dự báo ETA sai số cao khi có ùn tắc

Chuyển đổi

Mục tiêu: Nền tảng Lambda 24/7

Lưu trữ chuỗi thời gian phân tán

$+$ Kết hợp Sự cố giao thông TomTom

$\Longrightarrow$ Dự báo ETA thích ứng biến động

Xây dựng chuỗi khép kín: Crawl $\rightarrow$ Ingest $\rightarrow$ Store $\rightarrow$ Process $\rightarrow$ Serve

2. Đặc Trưng Dữ Liệu Lớn Thực Nghiệm (Mô Hình 4V)

1. Volume (Quy mô Dữ liệu)

- Theo dõi **504 xe buýt** trên **49 tuyến nội đô** Hà Nội.
- Vận hành 17h/ngày (05:00 – 22:00), chu kỳ 75–80s.
- Phát sinh **350.000 – 400.000 bản ghi/ngày**; tích lũy hàng triệu bản ghi cùng dữ liệu sự cố giao thông.

2. Velocity (Tốc độ Dòng xe)

- Tần suất nạp đạt **6–7 gói tin/giây** theo từng đợt quét.
- Đòi hỏi cơ chế thu nạp bền bỉ, hàng đợi đệm phân tán không gây nghẽn và độ trễ chuyển tiếp thấp (< 1s).

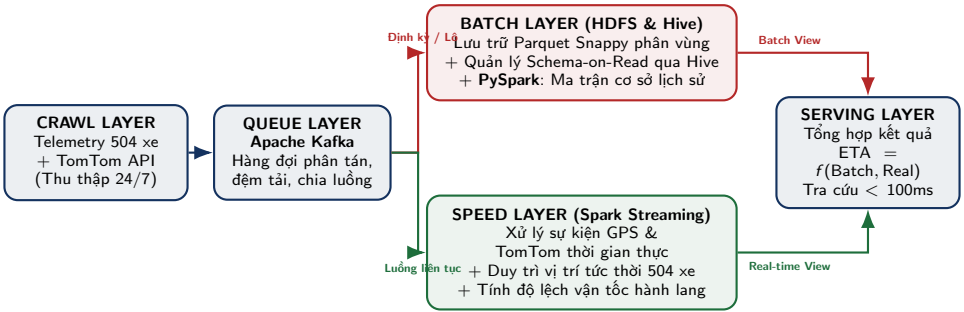
3. Variety (Đa dạng Cấu trúc)

- **Chuỗi thời gian GPS**: bán cấu trúc (JSON).
- **TomTom Traffic Incidents**: sự cố, độ trễ, vị trí ùn ứ.
- **Mạng lưới tĩnh**: lộ trình tuyến, tọa độ trạm dừng (bảng quan hệ có cấu trúc).

4. Value (Giá trị Thực tiễn)

- Khai phá ma trận thời gian di chuyển cơ sở lịch sử.
- Nắm bắt tức thì vận tốc dòng xe trên hành lang.
- Phục vụ hành khách dự báo thời gian chờ thực tế và cảnh báo hành lang ùn tắc cục bộ.

3. Ý Tưởng Kiến Trúc Tổng Thể (Mô Hình Lambda)



Nguyên lý cốt lõi

Tách bạch triệt để hai trách nhiệm: Luồng Lô giữ vai trò *mỏ neo lịch sử chính xác*, Luồng Luồng giữ vai trò *bù đắp biến động tức thời*.

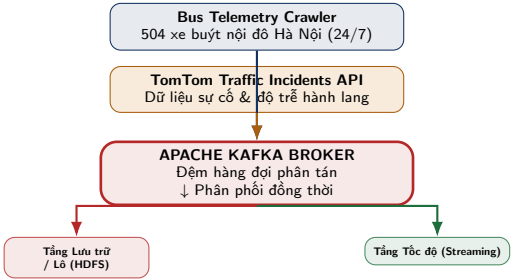
4. Khâu Thu Thập & Tiếp Nhận Dữ Liệu (Ingestion Pipeline)

1. Thu thập Tự động (Crawl Layer)

- **Telemetry 504 xe buýt (49 tuyến):** Quét định kỳ mỗi 75–80s, trích xuất tọa độ GPS, vận tốc tức thời, định danh xe và lộ trình.
- **TomTom Traffic Incidents API:** Quét liên tục các sự kiện dọc tuyến đường (tai nạn, tắc đường, công trường, thời gian chậm trễ).

2. Hàng đợi Phân tán (Apache Kafka)

- **Lớp đệm chịu tải (Buffer):** Tách rời Producers (Crawler) khỏi Consumers (Hạ tầng lưu trữ & xử lý).
- **Chống quá tải:** Hấp thụ các đợt bùng nổ dữ liệu (bursts) mà không gây rớt gói tin.



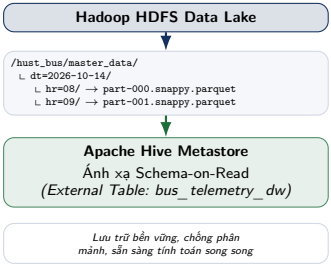
5. Khâu Lưu Trữ Phân Tán Bất Biến (Storage Layer)

Hồ Dữ Liệu Gốc (Hadoop HDFS)

- **Định dạng Parquet nén Snappy**: Lưu trữ hướng cột, nén dung lượng cao, tối ưu hóa I/O đọc lọc dữ liệu lớn.
- **Phân vùng Thời gian**: `/master_data/dt=.../hr=.../`
- **Partition Pruning**: Chỉ quét đúng ngày/giờ cần tính, bỏ qua 95% dữ liệu không liên quan.

Quản Trị Bảng với Apache Hive

- **Schema-on-Read**: Định nghĩa cấu trúc bảng ngoài (*External Table*) trỏ trực tiếp đến Parquet trên HDFS.
- Không sao chép dữ liệu, hỗ trợ truy vấn phân tích bằng SQL chuẩn.



6. Khâu Xử Lý Dữ Liệu (Processing Layer: 2 Luồng Lambda)

Luồng Lô (Batch Layer – PySpark)

- **Chu kỳ**: Chạy định kỳ trên dữ liệu lịch sử HDFS.
- **Làm sạch**: Lọc bản ghi GPS trôi dạt, xe về bãi.
- **Liên kết**: Ghép nối tọa độ với danh bạ trạm dừng và sự kiện TomTom Incidents.
- **Đầu ra: Batch View**:

Ma trận mỏ neo $T_{\text{base}}(S_k \rightarrow S_{k+1}, \text{giờ}, \text{thứ})$

Đặc trưng lịch sử dài hạn vững chắc

Luồng Tức Thời (Speed Layer – Spark Streaming)

- **Chu kỳ**: Xử lý liên tục luồng sự kiện từ Kafka.
- **Động học**: Theo dõi vị trí và vận tốc tức thời của các xe đang lăn bánh.
- **Sự cố**: Tiếp nhận cảnh báo tắc nghẽn TomTom tức thời trên từng đoạn đường.
- **Đầu ra: Real-time View**:

Hệ số bù vận tốc & sự cố tức thời Δ_{real}

Bắt trọn biến động giao thông hiện trường

7. Khâu Giải Quyết Bài Toán Dự Báo ETA (Serving Layer)

Nguyên lý Phân đoạn Hành trình

Chia lộ trình đến trạm đích S_{dest} thành các cặp trạm:

$$\text{Hành trình} = \sum_{k} (S_k \rightarrow S_{k+1})$$

Ý tưởng Công thức Tổng hợp ETA

$$\textbf{ETA} = f(\text{Batch View}, \text{Real-time View})$$

- **Batch View (Mỏ neo):** Thời gian chuẩn lịch sử theo phân đoạn và khung giờ.
- **Real-time View (Hiệu chỉnh):** Điều chỉnh theo vận tốc xe phía trước và sự cố TomTom đang xảy ra.



Tổng hợp Thời gian di chuyển:

$$T_k = T_{\text{base}}(S_k \rightarrow S_{k+1}) \times \alpha_{\text{real}} + \delta_{\text{TomTom}}$$

Kết hợp mỏ neo lịch sử và sự cố tức thời

Tra cứu Serving trực tiếp từ bộ nhớ (< 100ms)

8. Định Hướng Mở Rộng & Tổng Kết Đề Tài

Lộ Trình Phát Triển (Roadmap)

- **Giai đoạn 1 (Trọng tâm Học phần):**
  Hoàn thiện hạ tầng Dữ liệu Lớn chuẩn mực: Kafka → HDFS → Hive → Spark Batch & Streaming. Đảm bảo tính toán ổn định và lưu trữ mở rộng.
- **Giai đoạn 2 (Mở rộng Tương lai):**
  Khi kho HDFS tích lũy đủ dữ liệu lớn (vài tháng) → Huấn luyện mô hình **Machine Learning** tự động học tương tác phi tuyến phức tạp (thời tiết, mật độ, sự cố TomTom).

Tổng Kết Giá Trị Dự Án

- **Bám sát thực tế:** Giải quyết triệt để bài toán stateless của nguồn dữ liệu mở bằng hạ tầng 24/7.
- **Đầy đủ chuỗi khép kín:** Crawl → Đệm → Lưu trữ → Xử lý → Dự báo.
- **Khả thi & An toàn:** Sử dụng thuần túy hệ sinh thái cốt lõi của Apache, không chồng chéo công cụ dư thừa.

XIN CHÂN THÀNH CẢM ƠN!